Les données clients online

Tous droits réservés à STUDI - Reproduction interdite

Table des matières

I - Contexte 3

II - La donnée et son analyse 4

A. De la donnée à l'information 4
1. Qu'est-ce une donnée ? 4
2. Le V de la donnée 4

B. La classification des données 5
1. La classification selon la source : données offline, données online 5
2. La classification selon l'origine : first party data, second party data et third party data 6
3. La classification selon le niveau de traitement 7

C. Data Science 8
1. Data, Big Data, Open Data 8
2. Qu'est la Data science ? 8

D. Exercice : Quiz 9

III - Big Data 11

A. Big Data, Smart Data, Fast Data 11
1. Le Big Data 11
2. Le Fast Data 12
3. Le Smart Data 13

B. La stratégie Data 14
1. Aspects de la stratégie Data : approche défensive, approche offensive 14
2. L'appétence pour le Big Data 15
3. Devenir Data Driven 16

C. La protection des données personnelles 16
1. La donnée personnelle et les risques du Big Data 16
2. Le RGPD 17
3. La mise en conformité avec le RGPD 17

D. Exercice : Quiz 18

IV - Méthodes d'analyse des données online 20

A. Le Big Quali et le Big Data 20

B. La récolte et l'analyse des data 20
1. Susciter la contribution des clients 20
2. Optimiser l'évaluation du client en ligne 21
3. Data Visualisation 23
4. Méthodes d'analyse en temps réel 24
5. Data cleaning 24

C. Le stockage des data 25
1. Choix entre Data Lake et Data Warehouse 25
2. Le stockage distribué 25

D. Exercice : Quiz 26

V - Auto-évaluation 29

A. Exercice 29

Solutions des exercices 31

Tous droits réservés à STUDI - Reproduction interdite

I Contexte

Contexte

Depuis le début des années 2000, notre monde est devenu de plus en plus connecté grâce au numérique. Cette connexion est omniprésente du fait de la multiplication de supports connectés, allant de l'ordinateur aux montres connectés. Des millions de données sont émises chaque jour, donnant un potentiel considérable aux entreprises pour y détecter et analyser les besoins de leur cible. Or, moins de 10% des entreprises mettent en place une stratégie de gestion des données online.

L'objectif de ce cours est de comprendre l'importance et la valeur de la donnée online et de savoir l'utiliser afin de créer de la valeur client et renforcer ainsi le positionnement de l'entreprise.

Tous droits réservés à STUDI - Reproduction interdite

II La donnée et son analyse

A. De la donnée à l'information

1. Qu'est-ce une donnée ?

Une donnée est une information brute, qui peut prendre diverses formes, y compris des nombres, des textes, des images, des vidéos, des enregistrements sonores, etc. Cependant, une donnée brute n'a pas de signification en soi. Il est nécessaire de l'interpréter, de lui donner un sens. L'information comportant un sens spécifique sera contextualisée afin de permettre à son utilisateur de prendre une décision stratégique. Les données sont qualifiées de « *brutes* » lorsqu'elles n'ont pas été traitées ou contextualisées. En d'autres termes, une donnée qui a été traitée et qu'on lui a donné une signification devient une information.

On distingue généralement entre les données structurées et non structurées :

- **Données structurées** : elles sont organisées de manière formelle et sont généralement stockées dans des bases de données relationnelles. Les données structurées sont faciles à interroger et à analyser à l'aide de requêtes.
- **Données non structurées** : elles ne suivent pas un modèle préconçu et peuvent inclure des informations telles que du texte libre, des images, des fichiers audio ou vidéo. Les données non structurées nécessitent souvent des techniques plus avancées pour les analyser.

L'analyse des données présente un grand nombre d'avantages pour les entreprises :

- Elle permet d'identifier la cible et d'analyser ses besoins et son comportement. L'analyse des données permet de détecter des tendances, des modèles et des relations cachées au sein des données.
- Elle permet de planifier et d'organiser l'action de communication, ainsi que d'optimiser l'efficacité des actions de communication, grâce à un ciblage initial pertinent et à un pilotage de l'action en temps réel.
- Elle permet une optimisation de la stratégie marketing.
- Elle peut inspirer l'innovation en identifiant de nouvelles opportunités, en mettant en évidence des lacunes dans le marché, ou en suggérant de nouvelles approches pour résoudre des problèmes existants.
- Elle est un moyen efficace d'optimisation du canal de vente. Les entreprises peuvent utiliser l'analyse des données pour évaluer et améliorer l'efficacité opérationnelle.

2. Le V de la donnée

Le « *V de la donnée* » représente un ensemble de caractéristiques qui définissent les défis associés au traitement et à la gestion du big data. Ces caractéristiques sont généralement présentées sous la forme de six V.

Nous pouvons distinguer plusieurs dimensions :

- **Volume** : il fait référence à la quantité massive de données générées chaque jour. Les entreprises et les organisations sont confrontées à la gestion de volumes de données qui dépassent souvent leur capacité traditionnelle de stockage et de traitement. Lorsqu'on met en place une stratégie de Big Data, il faut choisir des solutions de stockage évolutives afin de pouvoir gérer le volume des données.
- **Vélocité** : elle vise la vitesse à laquelle les données sont générées, collectées et traitées. Les données peuvent aujourd'hui être générées en temps réel, ce qui nécessite des systèmes capables de traiter rapidement les flux de données continus. Pour bien gérer la vélocité des données, il faut mettre en place des systèmes de collecte de données rapides et efficaces.

Tous droits réservés à STUDI - Reproduction interdite

- **Variété** : il s'agit de la diversité des types de données. Les données peuvent être structurées (comme les données de base de données relationnelle), semi-structurées (comme le JSON, XML) ou non structurées (comme des documents texte, des images, des vidéos). Pour gérer la variété des données, il est important de choisir des plateformes polyvalentes, pouvant gérer aussi bien des données structurées que des données semi-structurées ou non structurées. Une plateforme très utilisée est Hadoop. Il est important également d'élaborer des stratégies de normalisation des données pour garantir une cohérence dans le traitement.
- **Véracité** : elle fait référence à la qualité ou à la fiabilité des données. Avec la prolifération des sources de données, il est crucial de s'assurer que les données sont précises et fiables. Pour garantir la véracité des données, il faut mettre en place un processus de correction des erreurs.
- **Volatilité** : il s'agit de la durée de vie des données. Certaines données peuvent être éphémères, tandis que d'autres peuvent nécessiter une conservation à long terme. Dans le cadre d'une stratégie de Big Data, il est important de mettre en place des mécanismes d'archivage clairs afin de séparer les données nécessitant une conservation à long terme, et celles qui sont éphémères.
- **Valeur** : elle concerne la capacité d'extraire de la valeur des données. Le défi ici est de transformer les données brutes en informations exploitables qui peuvent conduire à des décisions commerciales judicieuses. Il est important d'identifier les données ayant une réelle valeur commerciale pour l'entreprise.

B. La classification des données

Nous pouvons classer les données selon leur source ou selon leur origine.

1. La classification selon la source : données offline, données online

Les données récoltées peuvent avoir une origine hors ligne ou en ligne.

Les données hors ligne (offline data) font référence à des informations qui ne sont pas actuellement accessibles ou connectées à un réseau. Le plus souvent, ce sont des données internes à l'entreprise ou encore récoltées directement auprès du client lors d'un contact avec lui. En effet, ces données peuvent être récoltées lors d'un salon professionnel grâce à des formulaires prospects, grâce aux programmes de fidélité, lors des passages à la caisse, grâce à des questionnaires ou encore des systèmes de point de vente dits POS. Il peut également s'agir de données stockées localement sur des supports physiques, comme des clés USB, des tablettes ou des serveurs locaux. Il peut aussi s'agir de systèmes embarqués ou de capteurs utilisés notamment dans le cadre du pilotage de l'activité industrielle ou productive de l'entreprise.

Les données en ligne (online data en anglais) font référence à des informations accessibles et disponibles via une connexion Internet. Contrairement aux données hors ligne qui sont stockées localement sur un appareil ou un support physique, les données en ligne sont généralement hébergées sur des serveurs distants et peuvent être consultées à tout moment, à condition d'avoir une connexion Internet. Parmi cette catégorie, nous pouvons citer :

- **Bases de données en ligne** : il s'agit de bases de données hébergées sur des serveurs distants, accessibles via une connexion Internet, constituent des exemples de données en ligne. Ces bases de données peuvent stocker divers types d'informations, telles que des informations sur les clients, des données financières, etc. Ces données peuvent être publiques ou privées.
- **Réseaux sociaux** : il s'agit des informations partagées sur les plateformes de réseaux sociaux, telles que Facebook, Twitter, LinkedIn, Instagram, sont des exemples de données en ligne. Cela inclut les messages, les photos, les publications, les commentaires, etc.
- **Applications en ligne** : les applications web et mobiles nécessitent une connexion Internet pour fonctionner, et stockent souvent des données en ligne. Cela peut inclure des applications de messagerie, de productivité, de navigation, etc.

Tous droits réservés à STUDI - Reproduction interdite

- **Commerce électronique** : les informations sur les produits, les commandes, les transactions, etc., dans le domaine du commerce électronique, sont des exemples de données en ligne. Ces données sont généralement stockées sur des serveurs distants.
- **Données de streaming** : les vidéos, les musiques, les émissions de télévision, et d'autres contenus diffusés en continu via des plateformes telles que YouTube, Netflix, Spotify, sont des exemples de données en ligne.
- **Données en temps réel** : il s'agit d'informations en temps réel, collectées notamment grâce à des dispositifs de GPS ou de capteurs (IoT).
- **Données de recherche en ligne** : il s'agit des résultats de recherche, des articles, et autres contenus disponibles sur Internet constituent également des données en ligne.

2. La classification selon l'origine : first party data, second party data et third party data

Nous pouvons également classer les données selon leur origine, ou l'identification de la personne qui les récolte.

Tout d'abord, les first party data sont les données directement collectées par l'entreprise auprès de son public. Ces informations sont récoltées via les outils de travail de l'entreprise, comme le site internet, les questionnaires qu'elle administre auprès de sa clientèle, les échanges avec le SAV. Il peut s'agir par exemple de données récoltées par l'entreprise directement auprès de ces clients lors du passage en caisse ou encore lors de la création d'un compte client sur le site de l'entreprise.

Ces données sont réputées être fiables puisqu'elles émanent directement de la source cible. Il s'agit de données déclaratives. Elles sont faciles à récolter et à gérer dans les bases de données client. Elles sont plus accessibles car elles sont collectées à chaque contact avec le client.

Ces données peuvent être utilisées notamment pour analyser le comportement des clients, prédire les tendances futures et personnaliser les messages et les offres.

Les second party data proviennent d'entreprises partenaires. En effet, deux entreprises peuvent échanger leurs bases de données clients en vue d'élargir leurs fichiers prospects ou encore afin de proposer des offres combinées. Par exemple, une compagnie aérienne peut échanger ses données avec un groupe hôtelier.

Les données échangées sont les mêmes types de données que dans la catégorie de first party data. Cependant, une certaine vigilance s'impose quant à la protection des données personnelles. En effet, l'entreprise doit s'assurer que son partenaire respect également les règles de protection des données personnelles et que les données qui ont été échangées sont fiables. C'est ainsi que lors d'inscription sur certains sites internet, il est demandé à l'internaute de donner son autorisation en vue d'une transmission de ses données à des entreprises partenaires du site.

Les deux principaux avantages de ce type de données sont de toucher des nouveaux prospects et de réaliser des partenariats BtoB.

Un autre avantage de cette catégorie est la possibilité de scaler les données, c'est-à-dire de mettre à l'échelle des valeurs d'un ensemble de données. Par exemple, si je souhaite réaliser une modélisation en termes de prix des appartements dans un quartier spécifique, je peux utiliser ces données pour comparer les appartements sur la base de plusieurs caractéristiques : prix, surface ou nombre de pièces. Cela permet d'ajuster notre offre.

Les third party data sont des données achetées auprès d'une entreprise tierce. Cette entreprise, appelée également « *marchand de données* », collecte des données dans un objectif de les revendre. Elle peut revendre les données en l'état collecté ou alors après traitement ou classification.

L'entreprise qui achète des données auprès d'un marchand de données peut élargir son audience et son champ de prospection bien au-delà de sa zone d'origine. Elle peut aussi affiner son analyse de la cible et prévoir avec plus de justesse les modifications des tendances comportementales de la cible. Elle peut également identifier de manière plus aisée des nouvelles opportunités de marché.

Tous droits réservés à STUDI - Reproduction interdite

Cependant, le principal danger des third party data est celui de la protection des données personnelles. En effet, l'entreprise utilisant des données qui n'ont pas été récoltées de manière légale et en respect avec la législation sur la protection des données personnelle, est entièrement responsable et ne peut s'exonérer de responsabilité sous prétexte de l'absence de maîtrise du processus de récolte.

3. La classification selon le niveau de traitement

Nous pouvons également classer les données selon le niveau de traitement des données.

Tout d'abord, nous identifions les données primaires comme celles collectées directement à partir de sources originales. Ces données sont recueillies pour répondre à des objectifs spécifiques de recherche ou à des besoins particuliers. Elles sont également appelées données de première main ou données brutes. En d'autres termes, c'est le premier niveau de traitement de données récoltées.

Les données secondaires (second party data), en revanche, sont des données qui ont déjà été collectées, traitées et analysées par d'autres personnes ou organisations pour des besoins différents que ceux de l'entreprise. Ces données peuvent provenir de sources telles que des publications, des rapports gouvernementaux, des bases de données, des études de marché, ou encore des bases de données d'entreprises partenaires. Les données secondaires peuvent être réutilisées à des fins différentes de celles pour lesquelles elles ont été initialement collectées.

Il faut noter que le traitement des données secondaires est plus simple et facile puisque la phase de récolte est plus courte et qu'il n'y a pas d'étape de tri et d'élimination de données inutiles puisque le tri a été déjà réalisé.

Enfin, le terme de « *données tertiaires* » fait référence à des données qui ont subi un niveau supplémentaire de traitement ou d'agrégation après avoir été des données secondaires. Ces données peuvent avoir été combinées, agrégées ou soumises à une analyse plus approfondie. Il s'agit souvent de données récoltées sur des réseaux sociaux ou des moteurs de recherche comme Google et qui permettent d'analyser des comportements génériques des internautes. Des problèmes de protection des données personnelles apparaissent dans le cadre des données tertiaires. Du scandale de Cambridge Analytica jusqu'aux questions posées plus récemment sur les données récoltées par l'application TEMU, nous constatons les problématiques liées à ces données tertiaires.

Exemple

L'affaire de Cambridge Analytica a éclaté en 2018 et a suscité de vives préoccupations concernant la protection de la vie privée des utilisateurs de Facebook et l'utilisation potentielle des données à des fins politiques.

En 2014, un chercheur en psychologie, Aleksandr Kogan, a créé une application de quiz appelée « *thisisyourdigitallife* ». L'application téléchargeable sur Facebook prétendait s'inscrire dans un cadre de recherche dans le domaine de la psychologie. Environ 270 000 personnes ont téléchargé cette application, mais elle a également permis de collecter des données sur des millions d'amis de ces utilisateurs sans leur consentement. Transmission des données à Cambridge Analytica : Kogan a ensuite partagé les données collectées avec la société Cambridge Analytica, une entreprise britannique de consultation politique et de communication stratégique. Les informations incluaient des détails personnels, des préférences politiques et d'autres données sensibles.

Ensuite, Cambridge Analytica aurait utilisé ces données pour développer des profils psychographiques et cibler les électeurs avec des publicités politiques personnalisées. La société a travaillé sur plusieurs campagnes électorales, dont la campagne présidentielle de Donald Trump en 2016 et le référendum sur le Brexit au Royaume-Uni.

Tous droits réservés à STUDI - Reproduction interdite

L'un des problèmes posés dans cette affaire est la récolte de données sans le consentement des personnes. Celui-ci était en violation des politiques de confidentialité de Facebook. Ainsi, l'affaire a soulevé des questions sur la façon dont les plateformes en ligne traitent les données personnelles et sur la responsabilité des entreprises en matière de protection de la vie privée.

Le scandale a conduit à des enquêtes gouvernementales, des audiences parlementaires et des actions en justice contre Facebook et Cambridge Analytica. Il a également provoqué une prise de conscience accrue du public sur la manière dont les données personnelles sont utilisées et partagées sur les plateformes en ligne.

C. Data Science

1. Data, Big Data, Open Data

Az Définition

L'Open Data (ou Données Ouvertes) fait référence à la pratique de rendre librement disponibles au public certaines données, généralement sous forme électronique, afin de les utiliser, les redistribuer et les partager sans restrictions.

L'idée fondamentale derrière l'Open Data est de favoriser la transparence, l'innovation et la participation du public en fournissant un accès libre et gratuit à des ensembles de données utiles. Il faut également noter que certaines données sont rendues publiques sur obligation légale. Il s'agit notamment de certains documents comptables des entreprises, tels que les bilans et les comptes de résultat, et ceci dans un objectif de transparence et de protection des associés et des partenaires commerciaux. Ces données, souvent issues d'organismes publics et parapublics (comme l'INSEE ou la CNIL) servent notamment pour les études de marché.

L'Open Data présente un certain nombre de caractéristiques. Tout d'abord, les données ouvertes sont accessibles à tous, sans restrictions d'utilisation, de téléchargement ou de distribution. Elles sont généralement disponibles sur des plateformes en ligne ou des portails dédiés.

Une autre caractéristique de l'Open Data est celle de la liberté d'utilisation et d'exploitation. Les utilisateurs sont encouragés à réutiliser et à redistribuer les données ouvertes de manière créative. Cela peut inclure la création d'applications, d'outils d'analyse, de visualisations et d'autres produits dérivés. Cependant, il faut noter que le travail intellectuel produit grâce à l'exploitation des données publiques est une propriété privée de l'entreprise qui a réalisé ce travail.

Enfin, il faut distinguer les notions de Big Data et d'Open Data. En effet, si le Big Data se définit par l'ampleur des données émises, l'Open Data se détermine par son usage ouvert à tous. En d'autres termes, les Big Data ne sont pas forcément ouvertes, et les Open Data n'ont pas besoin d'être énormes.

2. Qu'est la Data science ?

Il est important de distinguer également le Big Data de la Data Science. En effet, le Big Data est lié aux outils informatiques, puisqu'il vise les outils d'émission, de transmission, de traitement et de stockage des données. La Data Science vise les méthodes et techniques d'analyse des données, qu'il s'agisse de mégadonnées ou pas.

Tous droits réservés à STUDI - Reproduction interdite

Az Définition

La data science, ou science des données en français, est un domaine multidisciplinaire qui utilise des méthodes, des processus, des algorithmes et des systèmes scientifiques pour extraire des connaissances et des insights à partir de données structurées et non structurées. La data science combine des éléments de statistiques, de mathématiques, d'informatique et de domaines spécifiques d'expertise pour analyser et interpréter des données complexes.

La Data Science permet de mettre en lumière des liens entre différentes données et de découvrir les tendances et comportements complexes des clients. En d'autres termes, elle permet aux entreprises de prendre des décisions ciblées et rapides en optimisant les chances de réussite.

La Data Science permet de créer un Data Product, c'est-à-dire un produit ou un service qui tire sa valeur de l'analyse ou de la manipulation de données. Les fonctionnalités de ce produit reposent sur l'utilisation et l'exploitation de données. Ce mode de création de nouveau produit a comme objectif d'apporter une satisfaction client optimale. Nous pouvons citer le cas des moteurs de recommandation qui utilisent l'analyse de données pour recommander un produit ou service en fonction du comportement passé de l'utilisateur. Nous pouvons également citer l'exemple des systèmes de recommandation de contenu utilisés par des plateformes telles que Netflix, Spotify, Youtube ou Tiktok.

D. Exercice : Quiz

[solution n°1 p. 31]

Question 1

La vélocité de donnée c'est :

- Le temps nécessaire pour émettre une donnée
- Le nombre d'informations traitées en un temps précis, par exemple en 1 jour.
- La vitesse à laquelle les données sont générées, collectées et traitées
- Le temps de validité d'une donnée

Question 2

Sont des données offline :

- **A** Les formulaires prospects sur un salon
- **B** Les POS
- **C** Les recherches sur Google
- **D** Les programmes de fidélité

Tous droits réservés à STUDI - Reproduction interdite

Question 3

Les données collectées par d'autres personnes que l'entreprise, comme des partenaires commerciaux, pour des besoins différents que ceux de l'entreprise sont :

- Des données primaires
- Des données secondaires
- Des données tertiaires
- Des données externes

Question 4

Les Open Data sont :

- Des données accessibles à tous sans restriction
- Des données publiées sur Internet
- Des données récoltées par l'État uniquement
- Des données liées aux recherches scientifiques

Question 5

La Data Science vise les données de Big Data :

- Vrai
- Faux

Tous droits réservés à STUDI - Reproduction interdite

III Big Data

A. Big Data, Smart Data, Fast Data

1. Le Big Data

Az Définition

Le terme de Big Data signifie « *mégadonnées* », « *grosses données* » ou encore « *données massives* ». Il s'agit d'un ensemble très volumineux de données généré grâce à une multitude d'outils digitaux, stocké et géré par des outils informatiques très performants.

Nous pouvons faire deux remarques par rapport à cette définition.

La première remarque concerne le volume généré de mégadonnées par jour. En 2022, nous émettions 2,5 trillions d'octets de données par jour. Ce volume n'arrête pas d'augmenter d'année en année, au point de doubler tous les deux ans. Cela pose multitude des questions, dont celle de leur stockage. En effet, le cloud a permis un stockage modulable en ligne. Néanmoins, les data centers où se trouvent les serveurs utilisés pour le stockage des données sont de plus en plus volumineux, et ont des besoins énergétiques considérables. Se pose alors la question de la gestion durable de ces data centers.

La deuxième remarque concerne le lien très fort qui existe entre l'évolution des TIC (Technologies d'Information et de Communication) et le Big Data. En effet, les ordinateurs sont devenus plus puissants, les outils informatiques plus variés, les serveurs plus performants et les supports connectés plus diversifiés. Tablettes, montres connectées, Linky, GPS font partie d'une multitude de supports émettant des données. De plus, l'apparition et multiplication des réseaux sociaux permet l'émission d'une masse de données considérable.

Les données récoltées sont une source précieuse pour l'entreprise. Elle les utilise pour adapter son offre, lancer des nouveaux produits, anticiper les situations pouvant porter préjudice à son activité.

Exemple

Netflix récolte les données de visionnage de ses utilisateurs et les utilise notamment pour construire des scénarios de films et séries télévisées à succès et primés. C'est notamment le cas de la série House of Cards, dont le scénario est entièrement basé sur les données récoltées sur la plateforme de l'entreprise. Voici comment Netflix utilise les données pour influencer la création de contenu :

- **Analyse des données de visionnage** : Netflix recueille des données sur la manière dont les utilisateurs interagissent avec sa plateforme. Cela inclut ce qu'ils regardent, quand ils le regardent, combien de temps, ils le regardent, et s'ils le terminent.
- **Analyse des préférences personnelles** : en utilisant des algorithmes de recommandation complexes, Netflix analyse les préférences individuelles des utilisateurs en fonction de leur historique de visionnage et de leurs évaluations. Cela permet à la plateforme de recommander du contenu personnalisé.
- **Création de contenus originaux** : Netflix utilise également ces données agrégées pour prendre des décisions stratégiques concernant la création de contenus originaux. Par exemple, si une certaine catégorie ou un genre spécifique est très populaire, Netflix peut décider de produire davantage de contenus similaires.

Tous droits réservés à STUDI - Reproduction interdite

- **Optimisation des bandes-annonces** : Netflix utilise des données pour personnaliser les bandes-annonces et les images de visionnées par les utilisateurs. Ces éléments sont choisis pour maximiser l'attrait en fonction des préférences passées.
- **Adaptation de la narration** : bien que Netflix ne crée pas directement des scénarios en fonction des données utilisateur, la plateforme peut utiliser des données pour adapter la narration ou les éléments visuels des contenus. Par exemple, Netflix a utilisé des données pour décider du moment optimal pour insérer des scènes percutantes dans certaines séries, en fonction des habitudes de visionnage des utilisateurs.

En résumé, Netflix utilise les données émises par les utilisateurs pour personnaliser l'expérience de visionnage, améliorer les recommandations, prendre des décisions stratégiques sur la création de contenu et optimiser la manière dont le contenu est présenté sur la plateforme.

2. Le Fast Data

Az Définition

Le terme « *fast data* » fait référence à un ensemble de technologies et de pratiques permettant la collecte, le traitement et l'analyse en temps réel de données à une vitesse élevée.

Contrairement au « *big data* », qui se concentre souvent sur le stockage et l'analyse de grandes quantités de données, le fast data se concentre sur la rapidité de traitement et d'analyse des données, en tirant parti de leur valeur en temps réel.

Le fast data présente un certain nombre de caractéristiques :

- **Vitesse** : le fast data se caractérise par la capacité à traiter rapidement les flux continus de données. Cela peut être crucial dans des domaines tels que les finances, les télécommunications, la santé et l'Internet des objets (IoT), où des décisions rapides sont nécessaires.
- **Analyse en temps réel** : le fast data implique l'analyse des données au fur et à mesure de leur émission, permettant une prise de décisions instantanées basées sur des informations récentes.
- **Réactivité** : les systèmes de fast data sont conçus pour être réactifs, capables de s'adapter rapidement aux changements dans les flux de données et de fournir des résultats en temps quasi réel.
- **Intégration au big data** : les données collectées rapidement peuvent être intégrées aux ensembles de données plus vastes pour une analyse plus approfondie à long terme.

Exemple

Le GPS Waze est un dispositif permettant de réaliser du fast data. L'application Waze a initialement été conçue comme un média social de navigation destinée aux automobilistes. De ce fait, les informations sont collectées et communiquées en temps réel. Grâce à la récolte et le traitement immédiats de ces données, nous identifions les utilisations suivantes :

- **Navigation en temps réel** : Waze fournit des itinéraires en temps réel en se basant sur les données de trafic actuelles et les conditions routières. Il ajuste automatiquement l'itinéraire pour optimiser le temps de trajet en fonction des informations en temps réel fournies par la communauté d'utilisateurs. Il suffit de laisser l'application ouverte pour qu'elle génère des données liées à la navigation.

Tous droits réservés à STUDI - Reproduction interdite

- **Information sur le trafic** : les utilisateurs de Waze signalent activement les embouteillages, les ralentissements, les accidents et d'autres problèmes de circulation. Les données en temps réel aident les autres conducteurs à éviter ces problèmes.
- **Signalement des dangers** : les utilisateurs peuvent signaler des incidents tels que des accidents, des objets sur la route, des animaux, des véhicules en panne, etc. Ces informations sont partagées avec la communauté pour améliorer la sécurité routière.
- **Partage de localisation en temps réel** : Waze permet aux utilisateurs de partager leur position en temps réel avec des amis ou des contacts, facilitant ainsi les rencontres et les déplacements coordonnés.

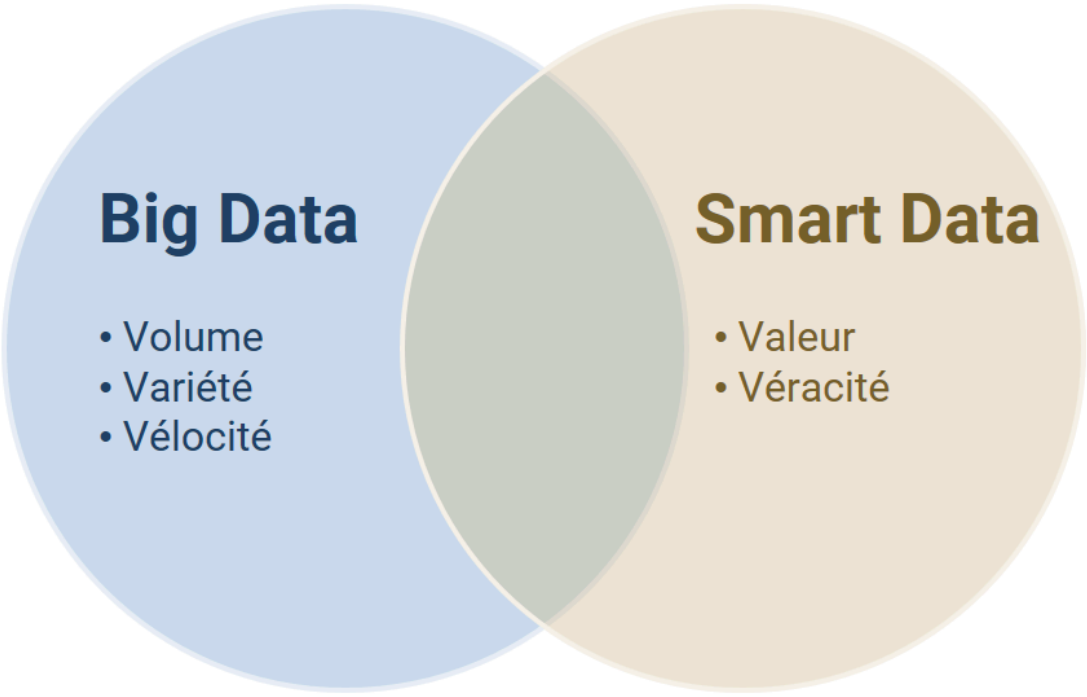
3. Le Smart Data

Az Définition

Le smart data, dit également « *données intelligentes* », consiste sélectionner les informations stratégiques à la source et les exploiter le plus rapidement possible afin de prendre des décisions rapides, tout en évitant de stocker les données inutiles.

Le smart data se base sur le développement des objets connectés et de l'intelligence artificielle. Le smart data diffère du big data puisque les données sont rapidement triées et ainsi exploitées immédiatement. Il s'agit d'une analyse en streaming des données issues du Big Data.

Nous constatons que les deux notions sont intimement liées grâce à la nature même des données. Le Big data répond essentiellement aux trois premières caractéristiques de la donnée, à savoir le volume, la variété et la vélocité, le Smart data répond essentiellement aux deux dernières, c'est-à-dire la valeur et la véracité.



Le fonctionnement du Smart data se base sur les principes suivants :

- **La collecte de données ciblée** : le smart data se concentre sur la collecte d'informations spécifiques et pertinentes pour répondre à des objectifs spécifiques. Cela peut inclure des données provenant de différentes sources, telles que les médias sociaux, les capteurs IoT (Internet des objets), les transactions clients, etc.

Tous droits réservés à STUDI - Reproduction interdite

- **Le nettoyage des données** : le processus de smart data implique souvent le nettoyage et la normalisation des données pour garantir leur qualité (data cleaning). Cela peut inclure la correction des erreurs, la suppression des doublons, la normalisation des formats, etc.
- **L'analyse avancée** : les techniques d'analyse avancée, telles que l'apprentissage automatique (machine learning), sont souvent utilisées dans le traitement du smart data. Ces techniques permettent de découvrir des modèles, des tendances et des relations dans les données.
- **La contextualisation des données** : les données sont souvent enrichies avec des informations contextuelles pour mieux comprendre leur signification. Par exemple, les données géographiques, temporelles ou démographiques peuvent être ajoutées pour fournir un contexte supplémentaire.
- **L'utilisation de l'intelligence artificielle** : l'IA est souvent intégrée dans les systèmes de smart data afin d'automatiser les processus d'analyse, identifier des schémas complexes et générer des insights significatifs à partir des données.
- **La protection de la vie privée et conformité** : étant donné les préoccupations croissantes concernant la vie privée des données, le smart data intègre souvent des pratiques et des technologies pour assurer la conformité aux réglementations en matière de protection des données.

L'utilisation du Smart Data par les entreprises présente les avantages suivants :

- Il permet d'améliorer la prise de décision stratégique et de diminuer les risques d'erreurs.
- Il contribue à l'optimisation des opérations commerciales en analysant les données commerciales et de production.
- Il permet de personnaliser les services et l'expérience client.
- Enfin, le Smart Data permet d'identifier des nouvelles opportunités commerciales, en analysant rapidement les données du marché.

Exemple

La Poste utilise le Smart Data depuis plusieurs années. L'entreprise a pu ainsi optimiser son réseau de distribution en utilisant des données géospatiales, des données de trafic ainsi que des modèles de prévision. Grâce à ces données, La Poste a pu :

- Réduire les délais de livraison
- Optimiser les itinéraires des postiers et par conséquent de livraison
- Prévenir les risques physiques encourus par les postiers
- Et enfin, de minimiser les coûts associés à la gestion du réseau.

B. La stratégie Data

1. Aspects de la stratégie Data : approche défensive, approche offensive

Il y a deux approches de la stratégie data : l'approche défensive et celle offensive.

Le principal objectif de l'approche défensive est de garantir la sécurité et l'intégrité des données, la vie privée des personnes concernées, le respect de la législation et les objectifs fixés par la gouvernance. De ce fait, la stratégie data vise à optimiser la captation des données, la standardisation des processus, de sécuriser le stockage et d'assurer l'accès aux données. Nous pouvons citer l'exemple de la stratégie data menée dans le cadre hospitalier, qui gère des données dites sensibles et dont la protection est strictement règlementée.

D'autre part, l'approche offensive vise à améliorer la compétitivité de l'entreprise et à augmenter sa rentabilité. Il s'agit d'identifier rapidement les nouvelles opportunités d'affaires, de mieux comprendre les besoins des clients afin d'y apporter une solution adéquate. La stratégie data se

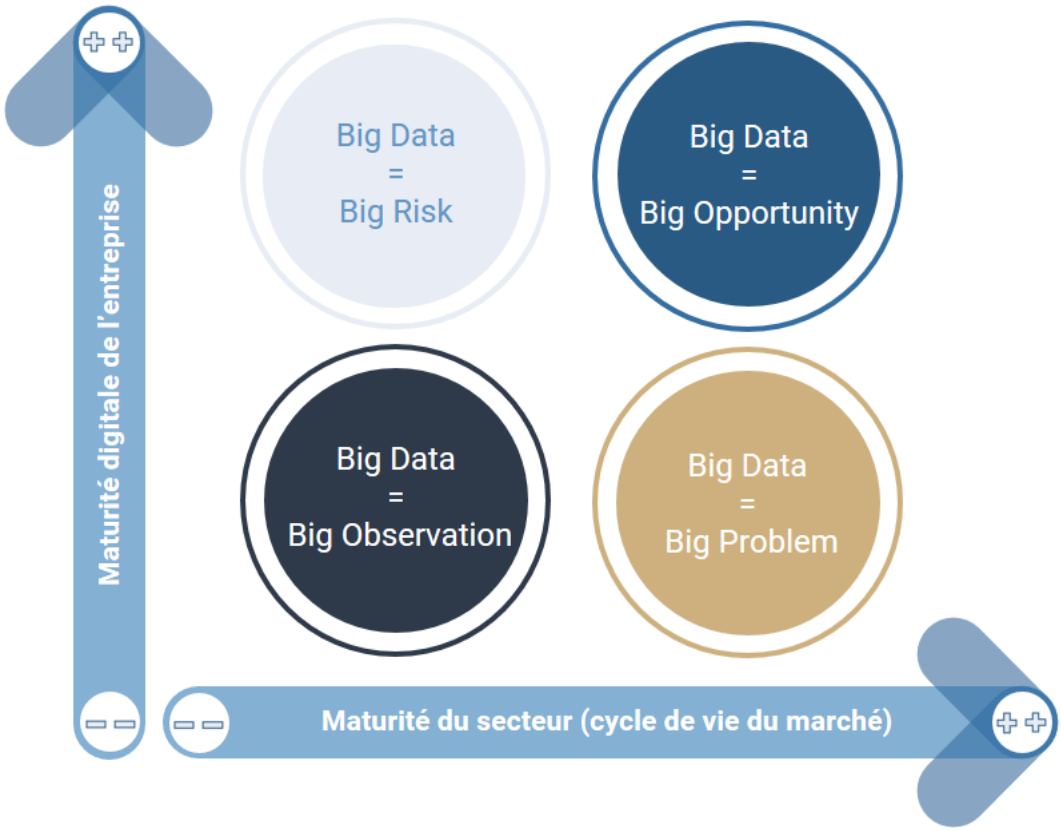
Tous droits réservés à STUDI - Reproduction interdite

structure autour de l'optimisation de l'analyse des données, leur modélisation, leur visualisation, leur enrichissement et leur transformation. Nous pouvons citer l'exemple du commerce de détail dont la réactivité à la concurrence et à l'évolution du marché incitent l'entreprise à récolter et à analyser des données de masse.

2. L'appétence pour le Big Data

L'appétence d'une entreprise pour le Big Data se réfère à sa volonté et à sa capacité à adopter et à tirer parti des technologies, des méthodologies et des approches associées au traitement et à l'analyse de grandes quantités de données. Cela implique généralement une disposition à investir dans des infrastructures, des compétences, des outils et des processus nécessaires pour exploiter le potentiel des données massives.

Si nous comparons l'appétence de l'entreprise pour le Big Data, avec la maturité du secteur d'activité face au Big Data, nous pouvons identifier quatre situations, comme le montre le schéma suivant :



Si le secteur d'activité n'est pas mature en termes de Big Data et que l'entreprise n'en a pas d'appétence particulière, nous sommes en situation de « *Big observation* ». En effet, nous observons le marché et nous pouvons être en attente d'une évolution potentielle. Le cas de l'artisanat, comme la boulangerie, semble se retrouver dans ce type de situation.

Par contre, si le marché comme à être mature ou nécessite l'utilisation du Big Data en vue de l'amélioration des performances économiques, mais que l'entreprise n'en a pas d'appétence, alors nous sommes en situation de « *Big Problem* ». En effet, nous pouvons citer le secteur de l'agriculture qui est très dépendant d'un grand nombre d'informations liées aussi bien à la météorologie que l'adaptation de la production et la rationalisation de l'eau par exemple. Nous voyons que ces besoins particuliers ont poussé certains agriculteurs à adopter des systèmes de gestion de leurs ressources performants, tandis que d'autres poursuivent les pratiques agricoles traditionnelles au risque de perdre leurs récoltes.

Si la maturité du secteur est faible, mais que l'entreprise a déjà investi dans la Big Data, nous sommes en situation de « *Big Risk* ». En effet, non seulement l'entreprise peut se heurter à un nombre de datas insuffisant pour réaliser son analyse, mais en plus, elle risque de ne pas pouvoir rentabiliser son investissement.

Tous droits réservés à STUDI - Reproduction interdite

Enfin, si le marché est mature et que l'entreprise a déjà investi au Big Data, alors nous sommes face à une situation de « *Big Opportunity* », c'est-à-dire l'entreprise sera en capacité d'identifier les opportunités économiques et commerciales qui s'offrent à elle.

3. Devenir Data Driven

Pour devenir Data Driven, c'est-à-dire pour fonder les décisions sur l'analyse approfondie des données plutôt que sur des intuitions ou des conjectures, une entreprise doit adopter une culture et des pratiques qui placent les données au cœur de la prise de décision et de l'ensemble de ses opérations. Ainsi, l'approche Data driven nécessite la présence des éléments suivants :

- L'engagement de la gouvernance : les dirigeants doivent soutenir les initiatives data-driven et montrer l'importance de la prise de décision basée sur les données.
- Définir une vision et des objectifs clairs pour toutes les parties prenantes. Ces objectifs doivent être mesurés grâce à des KPI afin d'évaluer le progrès.
- Former les collaborateurs : il faut impliquer les collaborateurs et pour cela il est important de les former.
- Développer l'infrastructure technologique : l'existence d'une infrastructure informatique capable d'analyser, de gérer et de stocker des données de masse est indispensable.

Il faut noter que les entreprises Data driven mettent souvent l'accent sur la compréhension approfondie des besoins et des comportements des clients. Cela permet de personnaliser les expériences, d'améliorer la satisfaction client et de stimuler la fidélité.

C. La protection des données personnelles

1. La donnée personnelle et les risques du Big Data

Az Définition

Selon la CNIL, une donnée personnelle est toute information se rapportant à une personne physique identifiée ou identifiable. En d'autres termes, une personne physique peut être identifiée directement (ex. nom et prénom) ou indirectement (par exemple le numéro de sécurité sociale). L'identification de la personne peut être réalisée à partir d'une seule donnée ou d'un croisement de données.

L'utilisation du Big Data comporte plusieurs risques pour la vie privée et la sécurité des données personnelles. En effet, les entreprises peuvent collecter une quantité importante de données, au-delà de ce qui est nécessaire, augmentant ainsi le risque de violation de la vie privée.

Un autre risque est celui relatif au profilage de la clientèle. L'analyse des grandes quantités de données permet la création de profils détaillés des individus. Le risque réside dans l'utilisation de ces profils pour prendre des décisions automatisées, par exemple, en matière d'emploi, de crédit ou d'assurance, ce qui peut entraîner la prise de décisions discriminatoires.

Un autre risque est celui de la violation de la confidentialité, surtout dans le cadre des données secondaires ou tertiaires. Certaines entreprises vendent des données à des partenaires commerciaux ou à des entreprises spécialisées afin de réaliser des revenus supplémentaires notamment. Mais au-delà de cette situation, la violation de la confidentialité peut se présenter en cas de cyberattaque et de vol des bases de données de l'entreprise.

Tous droits réservés à STUDI - Reproduction interdite

2. Le RGPD

Afin d'éliminer les risques sur les données personnelles, l'Union Européenne a adopté un texte phare, appelé RGPD « *Règlement Général sur la Protection des Données* ». Ce règlement s'applique à toute organisation, publique ou privée, qui traite des données personnelles pour son compte ou non et ceci dès lors qu'elle est établie sur le territoire de l'Union européenne et qu'elle cible des résidents européens. Afin de renforcer la protection des données personnelles des résidents européens, le RGPD oblige les entreprises stockant ce type de données de localiser leurs serveurs sur le territoire européen.

Exemple

L'outil Google Analytics réalise des transferts de données issues d'internautes européens vers les États-Unis en vue de faire des statistiques de fréquentation de sites Web. Ces sites utilisent ces données pour effectuer un ciblage publicitaire.

En 2020, la CNIL a été saisie par l'association autrichienne None of your business NOYB, qui a déposé 101 réclamations dans tous les États membres de l'Union européenne. Par ailleurs, l'homologue autrichien de la CNIL, la DSB, a décidé le 13/01/2022 que l'application Google Analytics enfreint le RGPD. L'argument de Google selon lequel les données sont cryptées a été jugé irrecevable par la DSB.

Le règlement soumet le traitement des données aux principes de licéité, de loyauté et de transparence. Il exige que la personne physique concernée donne son consentement de manière éclairée, explicite et volontaire. Elle a le droit de retirer son consentement à tout moment. En d'autres termes, les personnes ont le droit d'accès, de rectification et de suppressions de leurs données d'une base de données. Elles ont également le droit de s'opposer au traitement et le droit à la portabilité des données.

Le RGPD prévoit des sanctions financières sévères en cas de non-conformité, pouvant atteindre jusqu'à 4 % du chiffre d'affaires mondial annuel ou 20 millions d'euros, selon le montant le plus élevé.

Ainsi, ce règlement vise à renforcer la confidentialité et la sécurité des données personnelles, tout en donnant aux individus un meilleur contrôle sur l'utilisation de leurs informations personnelles.

3. La mise en conformité avec le RGPD

Le règlement RGPD prévoit un certain nombre d'obligations à destination des entreprises qui récoltent des données personnelles.

La première obligation est prévue par l'article 35 et concerne l'analyse d'impact sur la protection des données. Cette analyse, dite AIPD, consiste à identifier et diminuer les risques d'atteinte aux droits et libertés des personnes concernées par le traitement des données à caractère personnel. Cette obligation existe soit lorsque le traitement envisagé et prévu par la CNIL, soit lorsque le traitement remplit au moins deux des neuf critères suivants :

- Évaluation ou scoring (y compris le profilage) des internautes : le traitement vise à créer des profils comportementaux.
- Le traitement amène vers une décision automatique, pouvant conduire à une discrimination.
- Le traitement est utilisé pour observer, surveiller ou contrôler les personnes concernées.
- La collecte de données concerne des données sensibles ;
- Lorsqu'il s'agit de collecte de données personnelles à grande échelle.
- Lorsqu'il s'agit d'un croisement de données issues de traitements différents.
- Le traitement concerne les données de personnes vulnérables, ex. de patients ou personnes âgées.

Tous droits réservés à STUDI - Reproduction interdite

- Lorsqu'il y a usage d'une nouvelle technologie.
- Lorsque les opérations conduisent à autoriser ou refuser l'accès à un service ou un contrat.

Une deuxième obligation est celle de designer un DPO (délégué à la protection des données) dans certaines situations spécifiques. Cette obligation pèse sur les autorités et organismes publics, sur les entreprises réalisant des traitements à grande échelle, ou lorsqu'il y a un traitement systématique. Le DPO est responsable de superviser la conformité de l'entreprise avec le RGPD, de conseiller sur les questions liées à la protection des données, de coopérer avec l'autorité de contrôle, de servir de point de contact pour les personnes concernées et de mener des évaluations d'Impact sur la Protection des Données (AIPD) lorsque cela est nécessaire.

D. Exercice : Quiz

[solution n°2 p. 33]

Question 1

Le fast data c'est :

- Les données très volatiles
- Les données qui sont traitées rapidement
- Les données qui sont obsolètes rapidement
- Les données qui sont remplacées rapidement

Question 2

Le smart data c'est :

- Les données qui sont traitées rapidement
- Les données qui sont intéressantes pour l'entreprise
- Les données qui sont traitées rapidement en raison de leur intérêt stratégique
- Les données collectées et traitées en temps réel

Question 3

Une entreprise est data driven lorsque :

- **A** Elle fonde ses décisions sur les conjectures
- **B** La gouvernance soutient les décisions basées sur la data science
- **C** Elle dispose d'une infrastructure technologique capable de gérer la masse des données
- **D** Elle met l'accent sur la compréhension approfondie des besoins des clients

Tous droits réservés à STUDI - Reproduction interdite

Question 4

L'AIPD est obligatoire :

- Pour toutes les entreprises
- Pour toutes les autorités publiques
- Pour tout type de traitement de données
- Pour certains types de traitements de données

Question 5

La désignation de DPO est obligatoire :

- **A** Dès qu'il y a un traitement des données
- **B** Lorsque le traitement est systématique
- **C** Lorsque le traitement vise des données sensibles
- **D** Lorsque c'est une entité publique qui collecte les données

Tous droits réservés à STUDI - Reproduction interdite

IV Méthodes d'analyse des données online

A. Le Big Quali et le Big Data

Le Big Data a apporté des améliorations significatives aux études qualitatives en fournissant des avantages tels que l'accès à des volumes massifs de données non structurées, l'analyse automatisée des tendances, et la capacité à découvrir des motifs complexes dans les comportements humains.

Az Définition

Le Big Quali désigne la capacité à recueillir et à analyser une masse de données qualitatives en vue de prendre en compte toutes les facettes d'une marque.

Le Big Data permet de traiter rapidement des volumes massifs de données non structurées provenant de diverses sources, y compris les médias sociaux, les forums en ligne, les commentaires clients, etc. Grâce aux technologies d'analyse automatisée du langage naturel (NLP) nous pouvons comprendre et analyser le langage humain dans des données non structurées. Cela facilite l'exploration de vastes ensembles de textes, tels que les avis en ligne, les commentaires de clients, les discussions de forums, pour extraire des insights qualitatifs.

Les algorithmes d'apprentissage automatique peuvent détecter des thèmes récurrents, des opinions populaires, des sentiments et d'autres motifs qui pourraient ne pas être évidents dans des études plus petites. Grâce à ce type de traitement des données, nous pouvons identifier rapidement des tendances émergentes sur les marchés.

B. La récolte et l'analyse des data

1. Susciter la contribution des clients

Az Définition

Le marketing participatif consiste à demander l'avis et la participation des clients via des supports variés (blogs, chats, forums, réseaux sociaux, sondages et questionnaires en ligne).

Le management participatif repose sur le principe selon lequel l'utilisateur devient acteur à part entière de sa propre expérience et défini les modalités d'interaction avec la marque. Il constitue un moyen efficace pour l'entreprise de créer un lien permanent avec ses clients.

Afin de mettre en place une campagne de marketing participatif, il est important d'identifier la cible et ses besoins, de créer un message marketing efficace et engageant et enfin créer les outils digitaux adéquats.

Nous identifions deux dimensions à l'engagement participatif des clients. La première dimension porte sur les messages ou outils repérables objectivement, incitant à une participation régulière. Cette dimension favorise l'expression libre du client. La deuxième dimension est plutôt affective, elle crée un lien fort entre l'internaute et l'entreprise. C'est la confiance et la fidélité qui poussent le client à produire du contenu.

Tous droits réservés à STUDI - Reproduction interdite

Exemple

En 2021, l'entreprise Hasbro lance un sondage en ligne pour choisir seize nouvelles cartes. « *Le but du jeu reste le même, c'est le principal, rassure Philippe Pinoli, 49 ans, fan de la première heure et champion de France de Monopoly. L'idée est de moderniser certains textes et de délivrer des messages positifs et pédagogiques dans l'air du temps* », nous pouvons lire dans un article du journal Le Parisien présentant l'opération lancée par l'entreprise[1]. L'idée est de créer une nouvelle version sensible à l'écologie. Parmi les propositions de nouvelles cartes, nous retrouvons celle « *De la musique assourdissante tard dans la nuit ? Vos voisins n'apprécient pas ! Allez en prison !* » ou encore « *Vous avez organisé une fête entre voisins mais vous n'avez pas recyclé vos déchets ? Payez 100 $* ». L'objectif de cette opération est d'attirer davantage la jeunesse qui s'intéresse aux enjeux sociaux et climatiques



Source : Gadgeteer[2]

2. Optimiser l'évaluation du client en ligne

Les outils digitaux permettent de mettre en place une communication constante entre l'entreprise et le client. Au-delà d'un simple échange commercial, ils offrent des grandes possibilités d'interaction, et notamment le feedback client sur un produit, un service, voire l'entreprise en tant qu'entité. Or, si le contenu du feedback client devient bien plus riche grâce aux outils digitaux, il devient également beaucoup plus volatil. Chaque information est copiée, modifiée, interprétée, amplifiée, voire déformée sur la toile. Lorsqu'un avis est favorable, les internautes interagissent avec l'entreprise favorablement. Mais il suffit qu'un avis soit significativement négatif pour que les internautes se détournent de l'entreprise et de ses produits.

Exemple

La plateforme TripAdvisor permet d'évaluer les professionnels du secteur du tourisme et de l'hôtellerie-restauration. Lorsque les avis des internautes sont pilotés par l'entreprise, cela permet d'améliorer l'expérience client et de rendre le produit plus performant. Il est important d'utiliser ces données dans le cadre de l'amélioration continue du produit et du renforcement

1. https://www.leparisien.fr/societe/monopoly-bientot-une-nouvelle-version-ecolo-et-solidaire-24-03-2021-8429733.php
2. https://gadgeteer.co.za/monopoly-go-green-edition-lets-you-capitalize-sustainability-and-its-crafted-sustainable-materials/

Tous droits réservés à STUDI - Reproduction interdite

de l'image de marque. Par ailleurs, TripAdvisor favorise la visibilité des restaurants ou sites les mieux notés. De ce fait, le classement de l'entreprise dans cette plateforme est un réel levier de croissance.

Cependant, ces plateformes d'avis contiennent des dangers réels pour les entreprises et leur image de marque. Certes, la note globale affichée est censée représenter l'expérience que les clients ont vécue. Or, cette expérience est subjective et peut être vécu de manière différente selon les personnes et leurs envies.



Source : Tripadvisor

Les avis ci-dessus concernent le même restaurant. Or, nous pouvons constater les écarts dans l'appréciation des mêmes éléments. Les uns axent sur la facturation des frais de service et les portions des plats pour manifester leur mécontentement, tandis que les autres font l'éloge des plats et le digestif offert.

Face à un tel écart, il paraît indispensable d'apporter une réponse aux internautes qui expriment leur mécontentement afin de garantir la réputation et l'image numérique de l'entreprise.

L'entreprise doit mettre en place une stratégie pour solliciter et valoriser l'évaluation du client en ligne. Créer des communautés virtuelles et maîtriser leur fonctionnement permet à l'entreprise de développer sa notoriété. Nous parlons de marketing participatif.

Tous droits réservés à STUDI - Reproduction interdite

3. Data Visualisation

Az Définition

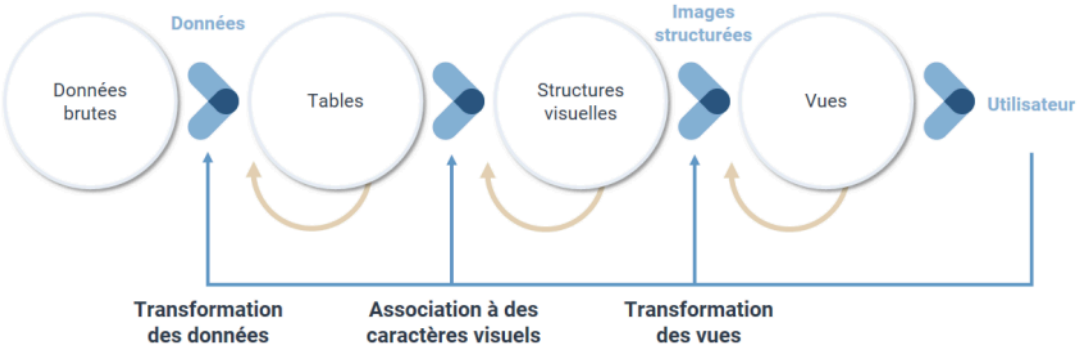
La data visualisation est un processus de traitement visuel des données qui s'étend de la collecte des données jusqu'à la représentation visuelle des résultats de l'analyse des données. Le traitement visuel des données vise à transformer des données brutes en une représentation graphique lisible et compréhensible pour l'utilisateur final.

La data visualisation est utilisée dans un objectif de décision. En transformant des données complexes en une information synthétique et simple, la data visualisation devient un outil d'aide à la décision stratégique pour l'entreprise. Elle accompagne les dirigeants dans l'analyse stratégique de l'environnement de leur entreprise de manière percutante.

D'autre part, la data visualisation est un outil de communication interne et externe de l'entreprise très efficace, puisqu'elle rend les données complexes accessibles par tout utilisateur.

Méthode

Ce processus de traitement des données se base sur le modèle de référence Dataflow, selon lequel il y a quatre étapes :

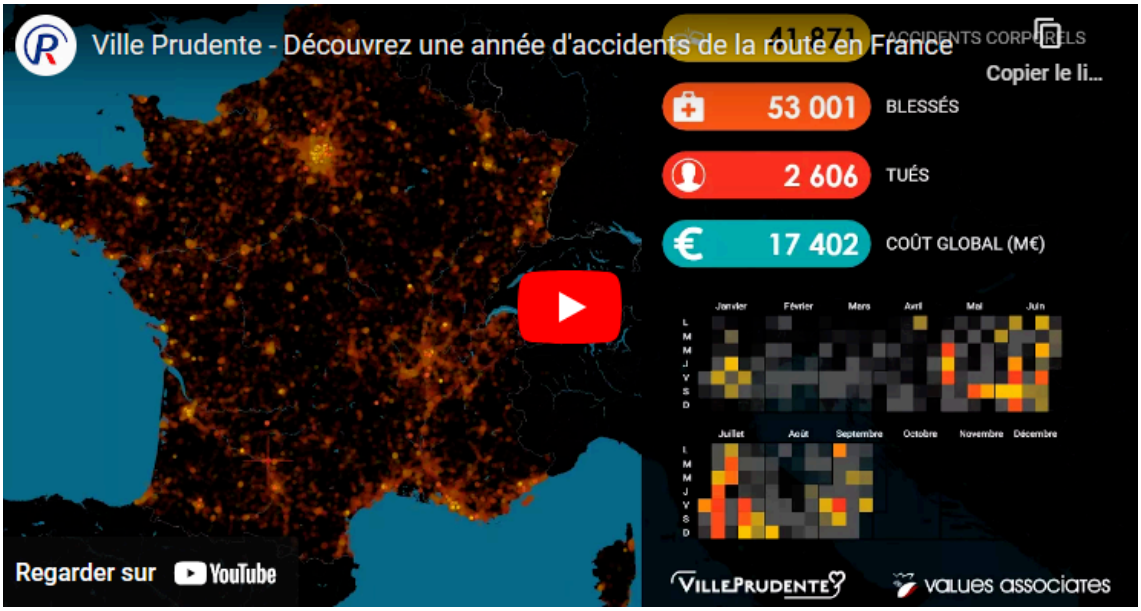


La première étape consiste en la collecte de données brutes. Pour cela nous pouvons notamment utiliser des bases de données en ligne ou des données récoltées par des objets connectés. Lors de la deuxième étape, les données sont transformées. Il s'agit de rajouter des métadonnées et d'éliminer les données inutiles. Cette étape permet de créer des tables de données. La troisième étape consiste à réaliser un « *mapping* » des données puisque les tables préalablement créées sont associées à des éléments visuels. Enfin, lors de la dernière étape, les éléments visuels deviennent structurés. Cela permet à l'utilisateur de les visionner de manière compréhensible.

Exemple

La data visualisation permet de piloter les actions menées par l'organisme ou entreprise. À ce propos, nous pouvons citer l'exemple de l'outil d'analyse statistique Ville Prudente développé par la société Values Associates. Cette application permet de visualiser l'accidentologie routière des villes sous forme d'un tableau de bord dynamique. Les mairies peuvent créer leur compte et accéder ainsi à l'évolution des accidents de route de leur ville depuis 10 ans.

Tous droits réservés à STUDI - Reproduction interdite



Source : villeprudente[3]

4. Méthodes d'analyse en temps réel

L'analyse des données en temps réel implique le traitement et l'analyse des données au fur et à mesure qu'elles sont générées. Cette approche est cruciale dans des domaines tels que les applications de surveillance en temps réel, la détection d'anomalies lors du processus de fabrication du produit, la personnalisation de l'expérience utilisateur, et d'autres scénarios nécessitant des réponses rapides aux données émergentes. Afin de traiter les données en temps réel, nous pouvons appliquer plusieurs méthodes. Citons quelques-unes :

La première méthode, appelée Stream Processing ou traitement de flux de données, consiste à effectuer des opérations d'agrégation, de filtrage et de transformation des données en temps réel. Cela permet de rectifier une action très rapidement. Cette méthode permet de détecter les anomalies en temps réel et ainsi identifier des comportements inhabituels ou des schémas inattendus.

Une autre méthode vise l'apprentissage automatique en ligne (Online Machine Learning). Ce type d'apprentissage implique la mise à jour continue des modèles d'apprentissage automatique à mesure que de nouvelles données arrivent. Cela permet d'augmenter l'expérience client et de créer des chatbot réactifs.

Enfin, la méthode de la création de tableaux de bord en temps réel permet aux utilisateurs de visualiser les données au fur et à mesure qu'elles sont générées.

5. Data cleaning

Face à l'augmentation fulgurante des données, il est important de procéder à un nettoyage de données afin de réduire les marges d'erreur dans nos processus d'analyse.

Az Définition

Le data cleaning est un processus dont l'objectif est d'identifier, puis de corriger les données inexactes ou non pertinentes dans une base de données. Ce processus a comme objectif d'améliorer la fiabilité et la valeur de chaque donnée, ainsi que la cohérence entre blocs de données.

3. https://www.villeprudente.fr/decouvrir-loutil/

Tous droits réservés à STUDI - Reproduction interdite

Méthode

Pour procéder à un data cleaning pertinent, il est important d'appliquer 6 bonnes pratiques :

- La surveillance des erreurs : il est important de tenir un registre et d'observer les sources des erreurs afin de les corriger.
- La normalisation et automatisation des processus : créer un processus à suivre par les utilisateurs afin d'optimiser la fiabilité des données
- La suppression des doublons pour alléger les bases de données
- La validation des données après le nettoyage.
- L'analyse des données lorsqu'elles sont normalisées, nettoyées et validées
- La communication des procédures auprès des équipes.

C. Le stockage des data

1. Choix entre Data Lake et Data Warehouse

Le stockage des données est un point important définissant la stratégie de Big Data de l'entreprise, puisqu'il implique des choix en termes de technologies utilisées, en termes d'investissements financiers et en termes de stratégie d'utilisation des données.

Nous avons le choix entre les Data Lake et les Data Warehouse.

Un Data Lake est une architecture de stockage de données qui permet de stocker de grandes quantités de données, qu'elles soient structurées, semi-structurées ou non structurées, à un coût relativement bas. Un Data Lake conserve les données brutes dans leur forme d'origine sans les transformer au préalable. De ce fait, les données sont en attente de traitement, suppression ou stockage. Enfin, les Data Lakes sont conçus pour être hautement évolutifs, ce qui signifie qu'ils peuvent gérer de grandes quantités de données en ajoutant simplement des capacités de stockage au fur et à mesure que cela est nécessaire.

D'autre part, un Data Warehouse est une infrastructure de stockage de données centralisée conçue pour faciliter le reporting et l'analyse des données pour prendre des décisions commerciales informées. Contrairement aux Data Lakes, qui stockent des données brutes non structurées, un Data Warehouse organise les données de manière structurée, les transforme en un format adapté à l'analyse, et les rend disponibles pour les utilisateurs finaux.

Les Data Warehouses sont optimisés pour les requêtes analytiques complexes et les rapports. Ils peuvent utiliser des techniques telles que l'indexation, l'agrégation précalculée, et le partitionnement des données pour améliorer les performances des requêtes. Enfin, certains Data Warehouses prennent en charge la gestion des versions et l'historique des données, ce qui permet de suivre l'évolution des données au fil du temps.

2. Le stockage distribué

Un stockage unique présente un certain nombre d'inconvénients, notamment en termes de taille de stockage ou encore en termes d'accessibilité ou de disponibilité en cas de panne. Les problématiques liées à la cybersécurité aggravent la vulnérabilité des données stockées sur des Data Lake ou Data Warehouse.

Tous droits réservés à STUDI - Reproduction interdite

Az Définition

Le stockage distribué fait référence à une architecture dans laquelle les données sont réparties sur plusieurs nœuds ou serveurs plutôt que d'être centralisées sur un seul système de stockage. Cette approche offre plusieurs avantages, notamment l'évolutivité, la réduction des coûts, la tolérance aux pannes, et la résilience et des performances améliorées pour la gestion de grandes quantités de données.

Exemple

De nombreuses entreprises utilisent des systèmes de stockage distribué pour gérer leurs volumes de données massives et les rendre accessibles à grande échelle. Il faut noter que plus l'entreprise collecte en masse des données, plus elle a besoin d'avoir recours à un stockage distribué. Voici quelques exemples d'entreprises connues qui utilisent ou ont utilisé des systèmes de stockage distribué :

- Google : Google utilise son propre système de stockage distribué appelé Google File System (GFS), qui a été conçu pour gérer les données à grande échelle dans son infrastructure.
- Amazon : Amazon utilise Amazon Simple Storage Service (S3), un service de stockage distribué qui permet aux entreprises de stocker et de récupérer des quantités massives de données.
- Facebook : Facebook utilise Apache Hadoop, un framework open source pour le stockage et le traitement distribué de grandes quantités de données. Ils utilisent également leur propre système de stockage distribué appelé Haystack pour stocker des milliards d'images.
- Netflix : Netflix utilise Apache Cassandra, une base de données distribuée hautement évolutive, pour stocker et gérer les données des utilisateurs, les métadonnées des films et séries, et plus encore.

D. Exercice : Quiz

[solution n°3 p. 35]

Question 1

La capacité de recueillir et d'analyser une masse de données qualitatives est appelée :

- Big Data
- Big Quali
- Smart Data
- Smart Quali

Tous droits réservés à STUDI - Reproduction interdite

Question 2

La datavisualisation permet de présenter :

- Des données brutes
- Des données non structurées
- Des données structurées
- Des données externes

Question 3

Sont des méthodes d'analyse en temps réel les méthodes suivantes :

- **A** Le Stream Processing
- **B** Le Online Machine Learning
- **C** Le OffLine Machine Learning
- **D** Les chatbot réactifs

Question 4

Le processus ayant comme objectif d'identifier et corriger les données inexactes ou non pertinentes s'appelle :

- Data Processing
- Data Analysing
- Data Cleaning
- Data suppressing

Question 5

Le système de stockage comportant uniquement des données structurées est appelé :

- Data Lake
- Data Warehouse
- Datadock

Tous droits réservés à STUDI - Reproduction interdite

Stockage distribué

Tous droits réservés à STUDI - Reproduction interdite

V Auto-évaluation

A. Exercice

1. **Histoire de Netflix**

   L'histoire de Netflix remonte à 1997, lorsque Reed Hastings et Marc Randolph ont fondé l'entreprise sous le nom de « *Netflix, Inc* ». Dans ses premières années d'existence, Netflix proposait un service de location de DVD par courrier.

   Au fil des années, Netflix a connu une croissance constante et a commencé à se diversifier. En 2007, l'entreprise a lancé son service de streaming en ligne, permettant aux utilisateurs de regarder des films et des séries directement via internet sur leur ordinateur.

   En 2010, Netflix a annoncé son expansion internationale et a commencé à proposer ses services dans plusieurs pays en dehors des États-Unis. L'année suivante, Netflix a introduit son modèle d'abonnement mensuel, permettant aux utilisateurs de regarder autant de contenus qu'ils le souhaitent, sans avoir à payer au cas par cas pour chaque film ou épisode.

   Au fil des ans, l'entreprise a investi massivement dans la production et la création de contenu original, lançant des séries à succès telles que « *House of Cards* », « *Stranger Things* » et « *The Crown* ».

2. **Le Big Data et Netflix**

   La stratégie de Netflix est concentrée sur l'analyse de la donnée. Netflix collecte une quantité importante de données sur ses utilisateurs, telles que les habitudes de visionnage, les évaluations, les recherches effectuées, les interactions avec l'interface utilisateur, les appareils utilisés, etc. Ils utilisent également des cookies et des pixels de suivi pour collecter des données supplémentaires.

   Cela leur permet de créer des modèles de recommandation personnalisés pour suggérer des contenus pertinents aux utilisateurs en fonction de leurs goûts et de leurs préférences.

   L'entreprise a développé son propre outil de data visualisation. L'objectif est d'améliorer les outils de reporting afin de communiquer des informations pertinentes, en temps réel. Dès 2011, l'entreprise investit dans l'exploitation des données de ses clients afin rationaliser le coût de production des séries dont tout le monde parle et attirer de nouveaux spectateurs.

   Toute la puissance de la stratégie de Netflix repose sur son algorithme, un algorithme de filtrage collaboratif qui analyse de façon très détaillée toutes les habitudes de chacun : « *à quel moment le téléspectateur interrompt un film ? Quels sont les passages du long métrage qu'il revoit ? Quel volume du son est réglé ? Etc… Au total, plus de 300 millions d'heures de visionnage seraient ainsi passées au crible, chaque semaine, par 900 ingénieurs* ».

3. **La réalisation de séries à succès**

   L'une des histoires les plus célèbres concernant l'utilisation des données de clients par Netflix concerne la création de la série « *House of Cards* ». En 2011, Netflix a décidé de produire une série télévisée originale basée sur le roman du même nom de Michael Dobbs. Au lieu de suivre les méthodes de production traditionnelles, Netflix a utilisé des données sur les habitudes de visionnage de ses utilisateurs pour orienter ses décisions.

   Netflix a analysé les données de visionnage de ses utilisateurs et a identifié des motifs et des caractéristiques communes parmi les utilisateurs qui appréciaient les films politiques, les séries dramatiques et les films réalisés par David Fincher, le réalisateur de « *House of Cards* ». Grâce à ces informations, Netflix a pris la décision audacieuse de commander directement deux saisons complètes de la série, sans même réaliser un pilote.

Question 1

[solution n°4 p. 37]

Quelle est la stratégie data de Netflix ? Justifiez votre réponse.

Tous droits réservés à STUDI - Reproduction interdite

Question 2

[solution n°5 p. 37]

En se basant sur la distinction Big Data, Open Data, Fast Data et Smart Data, quel type de données utilise Netflix pour créer du contenu original ?

Question 3

[solution n°6 p. 37]

Selon vous, quels sont les principaux risques de la méthode d'utilisation des données clients par Netflix, aussi bien dans le cadre de la suggestion de contenu aux utilisateurs que dans celui de la création de contenu original ?

Tous droits réservés à STUDI - Reproduction interdite

Solutions des exercices

Solution n°1

[exercice p. 9]

Question 1

La vélocité de donnée c'est :

- Le temps nécessaire pour émettre une donnée
- Le nombre d'informations traitées en un temps précis, par exemple en 1 jour.
- ✓ La vitesse à laquelle les données sont générées, collectées et traitées
- Le temps de validité d'une donnée

La vélocité vise la vitesse à laquelle les données sont générées.

Question 2

Sont des données offline :

- **A** Les formulaires prospects sur un salon
- **B** Les POS
- **C** Les recherches sur Google
- **D** Les programmes de fidélité

Les données hors ligne (offline data) font référence à des informations qui ne sont pas actuellement accessibles ou connectées à un réseau. Le plus souvent c'est des données internes à l'entreprise ou encore récoltées directement auprès du client lors d'un contact avec lui. Ainsi, les formulaires prospect, les POS et les programmes de fidélité sont considérés comme étant des données offline.

Question 3

Les données collectées par d'autres personnes que l'entreprise, comme des partenaires commerciaux, pour des besoins différents que ceux de l'entreprise sont :

- Des données primaires

Tous droits réservés à STUDI - Reproduction interdite

- ✓ Des données secondaires
- Des données tertiaires
- Des données externes

Les données secondaires, sont des données qui ont déjà été collectées, traitées et analysées par d'autres personnes ou organisations pour des besoins différents que ceux de l'entreprise.

Question 4

Les Open Data sont :

- ✓ Des données accessibles à tous sans restriction
- Des données publiées sur Internet
- Des données récoltées par l'État uniquement
- Des données liées aux recherches scientifiques

L'Open Data (ou données ouvertes) fait référence à la pratique de rendre librement disponibles au public certaines données, généralement sous forme électronique, afin de les utiliser, les redistribuer et les partager sans restrictions.

Question 5

La Data Science vise les données de Big Data :

- Vrai
- ✓ Faux

La Data Science vise les méthodes d'analyse des données, qu'elles proviennent du Big Data ou pas. Si le Big Data permet de disposer d'une masse d'informations importante pour alimenter l'analyse, il n'est pas indispensable, puisque la Data Science concerne l'analyse de tout type de données.

Tous droits réservés à STUDI - Reproduction interdite

Solution n°2

[exercice p. 18]

Question 1

Le fast data c'est :

- Les données très volatiles
- ✓ Les données qui sont traitées rapidement
- Les données qui sont obsolètes rapidement
- Les données qui sont remplacées rapidement

Le terme « *fast data* » fait référence à un ensemble de technologies et de pratiques permettant la collecte, le traitement et l'analyse en temps réel de données à une vitesse élevée.

Question 2

Le smart data c'est :

- Les données qui sont traitées rapidement
- Les données qui sont intéressantes pour l'entreprise
- ✓ Les données qui sont traitées rapidement en raison de leur intérêt stratégique
- Les données collectées et traitées en temps réel

Le smart data, dit également « *données intelligentes* », consiste sélectionner les informations stratégiques à la source et les exploiter le plus rapidement possible afin de prendre des décisions rapides, tout en évitant de stocker les données inutiles. Il s'agit d'une analyse en streaming des données issues du Big Data.

Question 3

Une entreprise est data driven lorsque :

- **A** Elle fonde ses décisions sur les conjectures
- **B** La gouvernance soutient les décisions basées sur la data science
- **C** Elle dispose d'une infrastructure technologique capable de gérer la masse des données

Tous droits réservés à STUDI - Reproduction interdite

D Elle met l'accent sur la compréhension approfondie des besoins des clients

Pour devenir Data Driven, c'est-à-dire pour fonder les décisions sur l'analyse approfondie des données plutôt que sur des intuitions ou des conjectures, une entreprise doit adopter une culture et des pratiques qui placent les données au cœur de la prise de décision et de l'ensemble de ses opérations.

Question 4

L'AIPD est obligatoire :

Pour toutes les entreprises

Pour toutes les autorités publiques

Pour tout type de traitement de données

✓ Pour certains types de traitements de données

L'AIPD est obligatoire lorsque le traitement remplit au moins deux des neufs types de traitements de données prévus par le RGPD.

Question 5

La désignation de DPO est obligatoire :

A Dès qu'il y a un traitement des données

B Lorsque le traitement est systématique

C Lorsque le traitement vise des données sensibles

D Lorsque c'est une entité publique qui collecte les données

Cette obligation pèse sur les autorités et organismes publics, sur les entreprises réalisant des traitements à grande échelle, ou lorsqu'il y a un traitement systématique.

Tous droits réservés à STUDI - Reproduction interdite

Solution n°3

[exercice p. 26]

Question 1

La capacité de recueillir et d'analyser une masse de données qualitatives est appelée :

- Big Data
- ✓ Big Quali
- Smart Data
- Smart Quali

Le Big Quali désigne la capacité à recueillir et à analyser une masse de données qualitatives en vue de prendre en compte toutes les facettes d'une marque.

Question 2

La datavisualisation permet de présenter :

- Des données brutes
- Des données non structurées
- ✓ Des données structurées
- Des données externes

Les données brutes sont d'abord collectées et nécessitent d'être structurées en éliminant les données inutiles. Ensuite le processus de datavisualisation permet de réaliser un « *mapping* » des données, lesquelles vont prendre la forme de données visuelles structurées.

Question 3

Sont des méthodes d'analyse en temps réel les méthodes suivantes :

- **A** Le Stream Processing
- **B** Le Online Machine Learning
- **C** Le OffLine Machine Learning

Tous droits réservés à STUDI - Reproduction interdite

D Les chatbot réactifs

L'analyse des données en temps réel implique le traitement et l'analyse des données au fur et à mesure qu'elles sont générées. Nous y retrouvons le Stream Processing et le Online Machine Learning dont l'exemple des chatbots réactifs est le plus connu.

Question 4

Le processus ayant comme objectif d'identifier et corriger les données inexactes ou non pertinentes s'appelle :

Data Processing

Data Analysing

✓ Data Cleaning

Data suppressing

Le data cleaning est un processus dont l'objectif est d'identifier, puis de corriger les données inexactes ou non pertinentes dans une base de données. Ce processus a comme objectif d'améliorer la fiabilité et la valeur de chaque donnée, ainsi que la cohérence entre blocs de données.

Question 5

Le système de stockage comportant uniquement des données structurées est appelé :

Data Lake

✓ Data Warehouse

Datadock

Stockage distribué

Data Warehouse organise les données de manière structurée, les transforme en un format adapté à l'analyse.

Tous droits réservés à STUDI - Reproduction interdite

[exercice p. 29]Solution n°4

La stratégie data de Netflix est une stratégie offensive. Pour rappel, l'approche offensive vise à améliorer la compétitivité de l'entreprise et à augmenter sa rentabilité. Il s'agit d'identifier rapidement les nouvelles opportunités d'affaires, de mieux comprendre les besoins des clients afin d'y apporter une solution adéquate. La stratégie data se structure autour de l'optimisation de l'analyse des données, leur modélisation, leur visualisation, leur enrichissement et leur transformation.

Or, Netflix utilise les data pour rationnaliser ses coûts d'exploitation, pour augmenter la satisfaction clients en suggérant des contenus pertinents aux utilisateurs en fonction de leurs goûts et de leurs préférences et en identifiant des nouvelles opportunités d'affaires, en créant des contenus à succès basés sur les données récoltées.

[exercice p. 30]Solution n°5

Netflix utilise des Big Data. Rappelons la définition du Big Data. Le terme de Big Data signifie « *mégadonnées* », « *grosses données* » ou encore « *données massives* ». Il s'agit d'un ensemble très volumineux de données généré grâce à une multitude d'outils digitaux, stocké et géré par des outils informatiques très performants. C'est justement le cas de Netflix qui récolte une grande masse d'informations et qui les analyse afin d'identifier des opportunités de marché. Ces données sont analysées en streaming.

Il est néanmoins important de noter que l'analyse des données récoltées poursuit des objectifs différents. Lorsque les données des utilisateurs sont analysées dans un objectif de leur faire des recommandations de contenu, il s'agit de Smart Data. En effet, dans ce cadre, les données doivent être analysées rapidement afin de s'adapter très rapidement aux atteintes du client.

En revanche, lorsqu'il s'agit d'améliorer la plateforme ou de créer du contenu original, il n'y a pas d'obligation particulière à ce que les données soient analysées rapidement. La méthode utilisée alors est celle du Big Data.

[exercice p. 30]Solution n°6

Nous pouvons identifier deux types de risque :

- Confidentialité des données : lorsque Netflix collecte et analyse les données de visionnage, il a accès à des informations sur les préférences et les habitudes de visionnage des utilisateurs. Il est important que Netflix protège ces informations de manière appropriée et les utilise uniquement dans le cadre de l'amélioration de son service et des recommandations personnalisées.
- L'analyse se base sur des algorithmes, c'est-à-dire statistiques, amenant vers un risque d'uniformisation de contenu. En d'autres termes, l'algorithme proposera le même type de film au même client, qui se retrouvera à regarder toujours le même type de films. Il s'agit du risque d'appauvrissement des propositions. De même, en se basant sur ces mêmes algorithmes pour réaliser du contenu, il y a le risque de voir de moins en moins de variété et de plus en plus de standardisation de ces mêmes contenus.

Tous droits réservés à STUDI - Reproduction interdite